Desafío Técnico: Data Scientist Lead

Optimización Logística

1. Contexto del Caso de Negocio

Una empresa de consumo masivo cuenta con una plataforma regional B2B que calcula y recomienda fechas de despacho dinámicas en el momento en que los clientes realizan sus pedidos. El objetivo fundamental del sistema es **aplanar la curva de demanda en los días pico, optimizar la capacidad de carga de los Centros de Distribución (CDs) y minimizar sobrecostos logísticos** por contratación de fletes de emergencia de última hora.

En zonas operativas de alta variabilidad urbana y comercial, el pronóstico de demanda estándar presenta desviaciones severas. Como **Lead Data Scientist**, tu misión será auditar la calidad del pronóstico actual sobre 6 centros de distribución, desarrollar un modelo analítico complementario que corrija las proyecciones, implementar una lógica de resiliencia ante falta de historial (*Cold Start*), y proponer una arquitectura en la nube (**AWS**).

2. Data package

Recibirás cuatro archivos CSV que simulan 60 días de operación continua (2026-01-01 a 2026-03-01) en 6 centros de distribución: CD_NORTE, CD_SUR, CD_CENTRO, CD_ESTE, CD_OESTE y CD_PACIFICO.

- **pedidos_historicos_genericos.csv**

Campo	Tipo	Descripción
centro_distribucion	string	Identificador del centro (CD_NORTE, CD_SUR, etc.)
fecha_despacho	**date (YYYY-MM-DD)**	**Fecha de entrega programada**
unidades_reales	**float**	**Cantidad real de unidades físicas entregadas**
canal_venta	**string**	**Canal de origen del pedido: PORTAL_WEB, AGENTE_COMERCIAL o ATENCION_TELEFONICA**

- **pronostico_demanda_generico.csv**

Campo	Tipo	Descripción
centro_distribucion	**string**	**Identificador del centro**
fecha_emision	**date**	**Fecha en que el sistema generó el pronóstico**
fecha_despacho	**date**	**Fecha objetivo de entrega**
horizonte	**string**	**Ventana de anticipación: D+1, D+2, D+3 o D+4**
unidades_pronosticadas	**float**	**Unidades estimadas por el modelo base**

- **capacidad_logistica_generica.csv**

Campo	Tipo	Descripción
centro_distribucion	**string**	**Identificador del centro**
fecha	**date**	**Fecha de operación**
capacidad_maxima_unidades	**float**	**Límite operativo máximo de transporte por día**

- **plan_entrega_clientes_generico.csv**

Registro a nivel cliente del plan de entrega acordado versus el comportamiento real de compra. Incluye 90 clientes (15 por CD).

Campo	Tipo	Descripción
cliente_id	**string**	**Identificador genérico del cliente (CLIENTE_001 … CLIENTE_090)**

centro_distribucion	**string**	**Identificador del centro que atiende al cliente**
canal_venta	**string**	**Canal de origen del pedido**
fecha_plan	**date**	**Fecha de entrega acordada en el plan con el cliente**
unidades_plan	**float**	**Unidades comprometidas en el plan**
fecha_compra_real	**date**	**Fecha real en que el cliente efectivamente compró/recibió**
unidades_reales	**float**	**Unidades realmente compradas**
fuera_de_plan	**int (0/1)**	**Indicador: 1 si la compra se realizó en una fecha distinta a la planificada**

3. Tareas Específicas del Desafío

Tarea 1: Diagnóstico de Calidad y Backtesting

Calcula las métricas de error WAPE y Bias para cada centro de distribución y para cada horizonte de planificación, utilizando las siguientes definiciones:

- WAPE = Σ |real − pronóstico| / Σ |real|
- Bias = Σ (real − pronóstico) / Σ |real| (valores positivos indican subestimación; negativos, sobreestimación)

Responde explícitamente:

1. ¿Qué centros subestiman de manera consistente la demanda real y cuáles la sobreestiman?
2. ¿Cómo se degrada la precisión del pronóstico (WAPE) a medida que la ventana temporal se extiende de D+1 a D+4?

Tarea 2 — Estado del plan de entrega

Con el dataset plan_entrega_clientes_generico.csv, responde:

1. ¿Existe un Bias en el plan de entrega? Es decir, ¿el plan (unidades y fechas) subestima o sobreestima sistemáticamente el comportamiento real de compra de los clientes?

2. ¿Cuál es el porcentaje de compras realizadas fuera del plan? Analízalo en total, por centro de distribución y por día de la semana planificado.
3. ¿Qué métricas adicionales calcularías para completar el panorama operativo? (ej. adhesión al plan por cliente, variación de fecha, variación de volumen, concentración de desvíos). Justifica por qué aportan.
4. Sabiendo que los clientes tienen preferencia por comprar en días específicos de la semana (con un pico los martes), ¿qué estrategia propondrías para aplanar la curva de demanda? Describe el mecanismo, cómo lo implementarías y qué KPI usarías para medir su efecto.

Esta tarea no requiere necesariamente el desarrollo de modelos predictivos, buscamos rigor analítico, criterio operativo y capacidad de traducir hallazgos en acciones de negocio.

Tarea 3 — Modelo complementario de forecast

Desarrolla un modelo en Python que combine la información histórica con el pronóstico base para generar un pronóstico corregido. Se espera como mínimo:

- Ingeniería de características: día de la semana, indicadores de picos de demanda y métricas móviles (rolling features).
- Una validación cruzada con origen rodante (rolling-origin backtest) que demuestre cuantitativamente el efecto del modelo sobre el WAPE global, en comparación con el modelo base.

Un resultado que no supere al modelo base no invalida tu entrega: si esto ocurre, documenta el análisis y justifica el hallazgo. Valoramos el criterio técnico y la honestidad analítica por encima de mejorar la métrica a toda costa.

Tarea 4: Regla de Resiliencia (Cold Start / Gate de Historia Mínima)

Diseñar e implementar un mecanismo de control (*Gate*) que evalúe la cobertura histórica disponible por centro de distribución:

- Si un centro tiene menos de 45 días de historia continua, el sistema debe activar un comportamiento de resguardo (fallback) seguro sin lanzar excepciones.
- Si cuenta con 45 días o más, habilita el entrenamiento del modelo complementario.
- Argumentar cuantitativamente las ventajas y riesgos de ajustar este umbral mínimo en producción.

Tarea 5: Arquitectura e Infraestructura Cloud (AWS)

Diseñar un diagrama conceptual de arquitectura en AWS indicando los componentes necesarios para operacionalizar la solución:

- Procesamiento Batch / Re-entrenamiento: Componente para tareas pesadas
- Servicio de Recomendación / Inferencia: Exposición de endpoints para app backend/web.
- Persistencia: Almacenamiento de métricas y estados.

El diagrama puede elaborarse en la herramienta de tu preferencia (draw.io, Lucidchart, Mermaid, etc.). Acompáñalo de una breve descripción de cada componente y sus interacciones. No se requiere código de infraestructura (Terraform, CDK, etc.), nos interesa el razonamiento de diseño.

4. Entregables

A. Código fuente (repositorio GitHub/GitLab o ZIP)

- Código modularizado en Python 3.11+ (limpio, tipado y documentado).
- Archivos de configuración de entorno (requirements.txt - pyproject.toml) y Dockerfile.
- Notebook ejecutable que procese los datasets y genere todos los resultados.

B. Presentación ejecutiva (deck de 9 diapositivas, PDF)

Diapositivas	**Contenido**
1–2	**Diagnóstico del error y hallazgos por CD**
3–4	**Estado operativo del plan de entrega: bias, adhesión y estrategia de aplanamiento (Tarea 2)**
5-6	**Metodología del modelo de corrección y resultados (Tarea 3)**
7-8	**Arquitectura AWS y estrategia de resiliencia, gate de 45 días. (Tarea 4 y 5)**
9-10	**Impacto en negocio: optimización de flota, reducción de fletes de emergencia, nivel de servicio y KPIs relevantes que propongas**

5. Condiciones del desafío

Condición	Detalle
Tiempo estimado	**8–16 horas de trabajo. No esperamos más de eso, prioriza la profundidad en lo que mejor conozcas y señala con honestidad lo que quedó fuera de alcance.**
Formato de entrega	**Enlace al repositorio GitHub, archivo ZIP, debe incluir el deck en PDF.**
Herramientas permitidas	**Cualquier librería de código abierto (pandas, scikit-learn, LightGBM, Prophet, etc.).**